Mejora de los modelos de calificación crediticia mediante máquinas de vectores de soporte

Participantes:

Daniela González Ortiz

Belén Shalom Dueñas Pacheco

Curso:

Machine Learning 2

Universidad Externado de Colombia

2026

Índice

1. Comprensión y sustentación del artículo 3
    1.1 Problema abordado 3
    1.2 Métodos utilizados 3
    1.3 Selección e ingeniería de características 4
    1.4 Datos y evaluación 4
    1.5 Resultados 5
    1.6 Supuestos y consideraciones 5
    1.7 Limitaciones 5
2. Planteamiento del problema 5
3. Estrategia de datos 6
4. Plan de modelamiento y línea base 7

1. Comprensión y sustentación del artículo

El artículo "Credit Scoring Models Enhancement Using Support Vector Machines", de Jinxin Xu y Yu Cheng, aborda el problema de la **clasificación del riesgo crediticio**. El objetivo es determinar si una persona que solicita un crédito presenta un riesgo bueno o malo para la entidad financiera. Para esto se pueden utilizar variables como el historial crediticio, los ingresos, el nivel de deuda, el comportamiento de pago y las características del crédito solicitado.

1.1 Problema abordado

Los autores plantean que los modelos tradicionales, como la **regresión logística y los árboles de decisión**, presentan algunas dificultades para representar relaciones no lineales y patrones complejos entre las variables. Por ejemplo, un determinado nivel de deuda puede representar un riesgo diferente dependiendo de los ingresos o del comportamiento crediticio del solicitante.

También se consideran problemas relacionados con la **escasez y el desbalance de los datos**. Cuando determinados grupos o eventos tienen pocas observaciones, el modelo puede aprender principalmente de los grupos con mayor representación y generar predicciones menos adecuadas para las poblaciones con menos datos.

Por esta razón, los autores estudian diferentes técnicas de Machine Learning que pueden capturar relaciones más complejas entre las características.

1.2 Métodos utilizados

El artículo considera diferentes métodos de clasificación, entre ellos regresión logística, árboles de decisión, Random Forest, Gradient Boosting, XGBoost y **Support Vector Machines (SVM)**.

Los autores explican que SVM busca encontrar un **hiperplano** que permita separar las observaciones pertenecientes a las diferentes clases. En este caso, el objetivo es diferenciar entre los solicitantes que presentan un riesgo crediticio bueno y aquellos que presentan un riesgo malo.

Cuando las clases no pueden separarse adecuadamente en el espacio original de las características, SVM puede utilizar una función kernel. Los autores utilizan el **kernel RBF (Radial Basis Function)**, también conocido como kernel gaussiano.

El kernel RBF se expresa como:

$$K(x, x') = exp(-\gamma \|x - x'\|^2)$$

En esta expresión, los autores describen x y x′ como vectores en el espacio de entrada. El término ‖x−x′‖ representa la distancia entre estos vectores, mientras que γ corresponde al parámetro que controla el ancho del kernel.

La idea principal es que el kernel permite trabajar con los datos en un espacio de características de mayor dimensión. De esta manera, datos que inicialmente no pueden separarse fácilmente mediante un hiperplano en el espacio original pueden llegar a ser separables en el espacio transformado.

Por ejemplo, si las observaciones se encuentran en un espacio de dos características, el uso del kernel permite representarlas en un espacio de mayor dimensión. En este nuevo espacio, SVM busca un hiperplano que separe las diferentes clases. Al regresar esta separación al espacio original, la frontera de decisión puede ser no lineal.

Una de las ventajas de utilizar el kernel es que no es necesario realizar explícitamente toda la transformación de las características. El kernel permite calcular directamente la relación entre los vectores en el espacio transformado.

1.3 Selección e ingeniería de características

Otro componente importante del artículo es la selección e ingeniería de características. Los autores utilizan técnicas como correlación, pruebas chi-cuadrado, RFE y métodos de selección iterativa, además de regularización LASSO.

La ingeniería de características busca crear nuevas variables o transformar las existentes para obtener información adicional. Entre las estrategias mencionadas se encuentran las **transformaciones logarítmicas, los términos de interacción, las estadísticas resumidas** y la creación de tasas o promedios.

También se consideran características temporales, como el tiempo transcurrido desde el último incumplimiento o los cambios en el comportamiento del cliente.

Además, los autores plantean la creación de características adaptadas al contexto específico del negocio, como indicadores propios del riesgo o del comportamiento de pago. Esto permite incorporar información relacionada con las características particulares del negocio que no necesariamente está presente en las variables originales.

Entre las características identificadas como importantes se encuentran el **saldo de la cuenta, la duración del crédito, el estado de pago del crédito anterior, el propósito del crédito y el monto del crédito**.

1.4 Datos y evaluación

Para realizar el experimento, los autores utilizan el German Credit Dataset, compuesto por 1000 observaciones, 20 características y una variable binaria que indica el riesgo crediticio.

Los modelos son evaluados mediante diferentes métricas, entre ellas accuracy, precision, recall, F1 y AUC. También se utiliza la curva ROC para analizar el comportamiento del modelo con diferentes puntos de corte.

La curva ROC relaciona la tasa de verdaderos positivos (TPR) con la tasa de falsos positivos (FPR). Un modelo presenta una buena discriminación cuando consigue una tasa alta de verdaderos positivos y una tasa baja de falsos positivos.

El AUC resume la capacidad de discriminación del modelo. Un valor cercano a 1 representa una excelente capacidad para diferenciar las clases, mientras que un valor cercano a 0.5 indica que el modelo tiene una capacidad de discriminación similar al azar.

Además, la curva ROC permite analizar diferentes umbrales de clasificación. Esto resulta importante en el contexto financiero porque el punto de corte puede modificarse dependiendo de las necesidades de la entidad y del costo asociado a cometer diferentes tipos de errores.

1.5 Resultados

Los resultados reportados por los autores muestran un mejor desempeño de SVM frente a los modelos tradicionales considerados. En particular, SVM obtiene una accuracy del 75% frente al 70% de la regresión logística, además de mejores resultados en otras métricas de evaluación.

Estos resultados respaldan el uso de SVM como una alternativa para problemas de clasificación crediticia en los que pueden existir relaciones no lineales entre las características de los solicitantes y su riesgo.

1.6 Supuestos y consideraciones

El enfoque supone que las características utilizadas contienen información suficiente para diferenciar entre los niveles de riesgo y que existe una relación que el modelo puede aprender entre las características del solicitante y su comportamiento crediticio.

Para SVM con kernel RBF es especialmente importante que las variables estén correctamente preparadas y escaladas, debido a que el cálculo del kernel depende de las distancias. También deben ajustarse parámetros como C y γ, ya que estos influyen en la complejidad de la frontera de decisión y, por tanto, en el desempeño del modelo.

1.7 Limitaciones

El artículo no presenta una sección extensa dedicada exclusivamente a las limitaciones del estudio. Sin embargo, pueden identificarse algunas consideraciones importantes.

En primer lugar, el experimento utiliza el German Credit Dataset, por lo que los resultados corresponden a una población y un contexto financiero específico. Por esta razón, los resultados no necesariamente pueden trasladarse directamente al contexto colombiano.

Además, aunque SVM permite capturar relaciones no lineales, su funcionamiento puede ser más difícil de interpretar que el de modelos como la regresión logística. Esto es relevante en el sector financiero, donde no solo interesa obtener una buena predicción, sino también poder explicar las decisiones tomadas por el modelo.

Finalmente, los problemas de escasez y desbalance de datos mencionados por los autores muestran que la calidad y representatividad de los datos también pueden afectar el desempeño de los modelos.

En conclusión, el artículo plantea que SVM con kernel RBF constituye una alternativa para mejorar la clasificación del riesgo crediticio cuando existen relaciones no lineales entre las variables. La metodología combina selección e ingeniería de características, entrenamiento de modelos de clasificación y evaluación mediante diferentes métricas, permitiendo analizar si los métodos de Machine Learning pueden mejorar la clasificación frente a modelos tradicionales.

2. Planteamiento del problema

A partir del artículo, el equipo formula el **problema predictivo** que reproducirá: una tarea de clasificación binaria de riesgo crediticio, en la que se busca determinar si un solicitante de crédito de consumo debe clasificarse como riesgo bueno o riesgo malo, replicando la lógica de separación de clases que los autores implementan mediante SVM sobre el German Credit Dataset.

Pregunta a responder. ¿Es posible clasificar de forma confiable el riesgo crediticio (bueno o malo) de un solicitante de crédito de consumo en el contexto colombiano, a partir de sus características sociodemográficas, financieras y del crédito solicitado, mediante un modelo SVM con kernel RBF, y en qué medida este modelo mejora el desempeño de una línea base y de otros modelos avanzados vistos en el curso?

Tipo de tarea. Clasificación binaria supervisada. La variable objetivo es categórica y toma dos valores: riesgo bueno (el solicitante cumple con sus obligaciones) y riesgo malo (el solicitante incurre en incumplimiento).

Variable objetivo y su relevancia. La variable objetivo, análoga a *Risk* en el artículo, corresponde al riesgo crediticio del solicitante. En el contexto colombiano y latinoamericano, este problema es especialmente relevante porque las entidades financieras enfrentan simultáneamente el reto de ampliar la bancarización y el acceso a crédito de consumo, y el de contener la cartera vencida y el riesgo de sobreendeudamiento de los hogares. Un modelo de clasificación de riesgo con mejor capacidad discriminante que los métodos tradicionales permite ajustar tasas, cupos y condiciones de forma más precisa, favoreciendo tanto la sostenibilidad de la entidad como el acceso responsable al crédito.

Método del artículo a reproducir y adaptar. Se reproducirá el método central del artículo: un clasificador SVM con kernel RBF (y, como comparación adicional propuesta por los propios autores, con kernel lineal), que busca el hiperplano óptimo de separación entre las clases en un espacio de características transformado mediante la función $K(x, x') = \exp(-\gamma\|x - x'\|^2)$. Del artículo también se reproduce el uso de regresión logística como modelo de comparación y la lectura de importancia de variables a partir de los coeficientes del SVM lineal.

La adaptación al contexto local consiste en: (i) redefinir las características del solicitante en términos plausibles para Colombia (ingresos y montos en pesos colombianos, tipo de

ocupación formal o informal, tipo de vivienda, nivel de ahorro, propósito del crédito); (ii) ampliar la comparación de modelos más allá de SVM frente a regresión logística, incorporando Random Forest y Gradient Boosting como modelos avanzados adicionales del curso, con el fin de situar el desempeño de SVM frente a otras familias de modelos no lineales; y (iii) incorporar herramientas de interpretabilidad moderna (SHAP) para complementar la lectura de coeficientes que el artículo únicamente aborda para el caso lineal.

3. Estrategia de datos

Vía elegida: simulación fundamentada. El equipo optará por una simulación fundamentada en lugar de un dataset real de solicitantes, dado que la información crediticia individual en Colombia (score de centrales de riesgo como Datacrédito o TransUnion, historial de pagos, ingresos declarados) está protegida por la normativa de habeas data financiero (Ley 1266 de 2008) y no se encuentra disponible en repositorios públicos con el nivel de detalle por individuo que exige este proyecto. La simulación permite reproducir, con fundamento estadístico, la estructura y las relaciones documentadas en el artículo, ajustadas a cifras y categorías propias del mercado de crédito de consumo colombiano.

Alcance regional de la restricción. Esta limitación no es exclusiva de Colombia: la mayoría de los países de la región cuentan con un marco normativo equivalente que impide el acceso público a microdatos crediticios individuales. En México, los burós de crédito están regulados por las leyes del sistema financiero y por la Ley Federal de Protección de Datos Personales en Posesión de los Particulares, que restringe el uso de la información al fin específico del otorgamiento de crédito. En Perú, la Ley N.º 27489 regula a las centrales de riesgo (supervisadas por la SBS) y la Ley N.º 29733 de Protección de Datos Personales exige el consentimiento del titular para el tratamiento de su información. En Chile, la Ley N.º 21.719 (que reemplaza a la Ley 19.628 y entrará en vigencia plena en diciembre de 2026) refuerza las exigencias sobre datos personales, incluidos los financieros. En Argentina rige la Ley 25.326 de Protección de Datos Personales, aunque el Banco Central permite consultas individuales puntuales a través de la Central de Deudores del Sistema Financiero, sin que ello habilite la descarga masiva de microdatos con fines de investigación. En Brasil, la Lei Geral de Proteção de Dados (LGPD, Ley 13.709 de 2018) somete a Serasa, SPC y Boa Vista a restricciones equivalentes. En consecuencia, la estrategia de simulación fundamentada adoptada en este proyecto sería igualmente necesaria si el equipo hubiera optado por cualquier otro país de la región, y las cifras agregadas que sí publican las respectivas superintendencias financieras (tasas de cartera vencida, indicadores de morosidad por segmento) constituyen la fuente más adecuada para calibrar los supuestos de la simulación.

Estructura que se reproducirá. La simulación replicará el esquema de variables del German Credit Dataset, adaptando nombres, unidades y categorías al contexto local:

- **Variables sociodemográficas:** edad, género y tipo de ocupación (informal, formal no calificado, formal calificado, alta calificación), como proxy de la variable *Occupation* del artículo.

- **Variables patrimoniales:** tipo de vivienda (propia, arrendada, familiar), nivel de ahorro (bajo, medio, alto, muy alto) y saldo en cuenta de ahorro o corriente expresado en pesos colombianos, análogos a *Savings accounts* y *Checking account balance*.
- **Variables del crédito solicitado:** monto en COP, plazo en meses y propósito del crédito (vehículo, libre inversión, electrodomésticos, educación, remodelación, negocio, otros), análogas a *Credit amount*, *Duration* y *Purpose*.
- **Variable de comportamiento previo:** estado de pago de créditos anteriores (sin créditos previos, al día, mora leve, mora severa), análoga a *Payment Status of Previous Credit*.
- **Variable objetivo:** riesgo crediticio (bueno / malo).

Relaciones y proporciones plausibles. Las relaciones entre variables y la variable objetivo se calibrarán siguiendo la dirección e importancia relativa reportadas por los autores para los coeficientes del SVM lineal: no tener cuenta bancaria y un mayor monto de crédito se asociarán con mayor probabilidad de riesgo malo; un buen historial de pago previo se asociará con menor riesgo; y el propósito y la duración del crédito modularán la probabilidad de forma consistente con la magnitud reportada por los autores. La proporción de la clase minoritaria (riesgo malo) se fijará alrededor del 20%–25%, un desbalance moderado, coherente con cifras de deterioro de cartera de consumo reportadas para el sistema financiero colombiano, y más leve que el desbalance del 30% del German Credit Dataset, con el fin de introducir un reto adicional de clasificación en presencia de clases no balanceadas.

Tamaño y calidad inicial del conjunto. El conjunto simulado tendrá al menos 6.000 registros, superando el mínimo de 5.000, con el fin de permitir una partición robusta en entrenamiento, validación y prueba, además de validación cruzada anidada. La versión base del dataset se generará sin valores faltantes; posteriormente se introducirá de forma controlada un porcentaje reducido (3%–5%) de valores faltantes y de ruido en variables numéricas, con el fin de ejercitar las etapas de imputación y limpieza en la siguiente fase del proyecto sin comprometer la validez de la estructura simulada.

4. Plan de modelamiento y línea base

Modelos avanzados a comparar. Siguiendo el método del artículo, el modelo central del proyecto será un SVM con kernel RBF, comparado con un SVM de kernel lineal, tal como lo hacen los autores. Adicionalmente, y aprovechando las técnicas avanzadas del curso, se incorporarán Random Forest y Gradient Boosting como modelos de ensamble no lineales, con el fin de contrastar el desempeño de SVM frente a otras familias de modelos capaces de capturar relaciones no lineales en los datos de riesgo crediticio.

Métrica principal de evaluación. Dado el desbalance moderado de clases y el hecho de que el costo de un falso negativo (otorgar un crédito a un solicitante que resultará de mal pagador) es considerablemente mayor que el de un falso positivo (rechazar a un buen pagador), la métrica principal será el F1-Score y el AUC-ROC de la clase riesgo malo, complementados con el

recall de dicha clase. La accuracy se reportará como referencia, siguiendo el criterio del artículo, pero no se usará como criterio de selección del mejor modelo, por su sensibilidad al desbalance de clases.

Estrategia de validación. Se realizará una partición inicial estratificada 80/20 en entrenamiento y prueba. Sobre el conjunto de entrenamiento se aplicará validación cruzada estratificada ($k = 5$) para el ajuste de hiperparámetros —C y γ para SVM; profundidad, número de árboles y tasa de aprendizaje para Random Forest y Gradient Boosting—, integrando todas las transformaciones (escalamiento, codificación, balanceo) dentro de un Pipeline para evitar fuga de información entre particiones.

Modelo de línea base. Como referencia mínima se construirá un clasificador de mayoría, que predice siempre la clase mayoritaria (riesgo bueno). De forma adicional, y replicando explícitamente la comparación que el artículo realiza entre SVM y regresión logística, se construirá una regresión logística simple —modelo del nivel de Machine Learning I— como segunda línea base. El desempeño de SVM, Random Forest y Gradient Boosting se medirá frente a ambas líneas base, con el fin de cuantificar la mejora aportada por los métodos avanzados del curso.